


Università degli studi di Padova

DIPARTIMENTO DI MATEMATICA 'TULLIO LEVI-CIVITA'

CORSO DI LAUREA IN INFORMATICA



**Valutazione di pgvector come
database unificato per RAG.**

Tesi di laurea triennale

Relatore

Marco Zanella

Laureando

Davide Lorenzon

Matricola 2101075

I hate perfection. To be perfect is to be unable to improve any further.

— Kurotsuchi Mayuri

Ringraziamenti

Innanzitutto, vorrei esprimere la mia gratitudine al Prof. Marco Zanella relatore della mia tesi, per l'aiuto e il continuo sostegno fornitomi durante la stesura del lavoro.

Desidero ringraziare con affetto i miei genitori e i miei parenti per il sostegno e per essermi stati vicini durante gli anni di studio.

Ho desiderio di ringraziare poi i miei amici per tutti i bellissimi anni passati insieme.

Ci tengo infine a ringraziare i colleghi di Pat SRL e il tutor aziendale Davide Bastianetto per avermi dato l'opportunità di lavorare a questo progetto.

Padova, Settembre 2026

Davide Lorenzon

Sommario

Il presente documento descrive il lavoro svolto durante il periodo di stage curricolare, della durata di circa trecentoventi ore, dal laureando Davide Lorenzon presso l'azienda Pat SRL. Lo stage è stato condotto sotto la supervisione del tutor aziendale Davide Bastianetto, mentre il prof. Marco Zanella ha ricoperto il ruolo di tutor accademico.

Al centro di questo elaborato vi è la progettazione e lo sviluppo di un sistema *RAG_G*. Questa architettura è oggi fondamentale poiché permette agli *LLM_G* di accedere a basi di conoscenza private e informazioni aggiornate senza la necessità di ricorrere a costosi processi di retraining, abbattendo drasticamente il rischio di allucinazioni da parte dell'Intelligenza Artificiale.

Lo scopo principale del progetto è valutare l'adeguatezza, la fattibilità tecnica e le performance dell'estensione *Pgvector_G* per PostgreSQL, impiegandola come database unificato per l'intera pipeline RAG. Nello specifico, l'obiettivo è verificare se tale tecnologia possa supportare efficacemente l'indicizzazione dei documenti, la ricerca ibrida (combinando ricerca full-text e semantica), l'applicazione di strategie di ranking avanzate e la correlazione relazionale con entità strutturate.

Per convalidare questa ipotesi e fornire una misura rigorosa della qualità del sistema, l'infrastruttura progettata verrà sistematicamente sottoposta a test comparativi contro una pipeline equivalente basata su *Elasticsearch_G*, tecnologia attualmente adottata all'interno dell'impresa.

L'utilità e il valore aggiunto di questa ricerca risiedono nella potenziale semplificazione dell'infrastruttura IT aziendale. Gestire dati relazionali, testuali e vettoriali all'interno di un unico ecosistema (il database unificato) permetterebbe di superare il paradigma della persistenza poliglotta, eliminando la necessità di mantenere sistemi separati. Questo approccio promette di abbattere l'overhead di sincronizzazione dei dati, ridurre i costi di manutenzione sistemistica e garantire transazioni più sicure.

Sono previsti test comparativi tra il nuovo sistema e il sistema attualmente in uso.

Organizzazione del testo

- Il **primo capitolo** introduce l'azienda, il progetto e le motivazioni che mi hanno portato a sceglierlo;
- Il **secondo capitolo** descrive l'azienda, il progetto e l'organizzazione del lavoro, definendo gli obiettivi e analizzando i rischi;
- Il **terzo capitolo** descrive l'analisi dei requisiti del progetto, indicando un'analisi degli utenti, i casi d'uso e il tracciamento dei requisiti;
- Il **quarto capitolo** descrive le tecnologie esistenti per risolvere i problemi indicando gli aspetti teorici alla base, gli strumenti che sono stati scelti e con quali criteri;
- Il **quinto capitolo** descrive nel dettaglio le problematiche sorte nel concreto durante lo svolgimento del progetto;
- Il **sesto capitolo** raggruppa le conclusioni tratte dallo svolgimento del progetto.

Convenzioni tipografiche

Durante la stesura del testo ho scelto di adottare le seguenti convenzioni tipografiche:

- Gli acronimi, le abbreviazioni e i termini di uso non comune menzionati vengono definiti nel glossario, situato alla fine del documento (p. 19);
- Per la prima occorrenza dei termini riportati nel glossario viene utilizzata la seguente nomenclatura: *Termine_G*
- I termini in lingua straniera non di uso comune o facenti parti del gergo tecnico sono evidenziati con il carattere *corsivo*;
- I nomi di funzioni o variabili appartenenti ad un linguaggio di programmazione vengono scritte con un carattere **monospaziato**;
- Le citazioni ad un libro o ad una risorsa presente nella bibliografia (p. 21) saranno affiancate dal rispettivo numero identificativo, es. [1];
- I blocchi di codice sono rappresentati nel seguente modo:


```

1  float Q_rsqr( float number ){
2      long i;
3      float x2, y;
4      const float threehalfs = 1.5F;
5      x2 = number * 0.5F;
6      y = number;
7      i = * (long * ) &y;
8      i = 0x5f3759df - (i>>1);
9      y = * (float * ) &i;
10     y = y * ( threehalfs - ( x2 * y * y ) );
11     //y = y * ( threehalfs - ( x2 * y * y ) );
12     return y;
13 }

```

Codice 1: Codice d'esempio.

Indice

1	Introduzione	1
1.1	L'azienda	1
1.2	Il progetto	1
1.3	Scelta del progetto	3
2	Descrizione stage	5
2.1	Competenze da apprendere	5
2.2	Vincoli	5
2.3	Pianificazione	6
2.4	Analisi dei rischi	6
2.4.1	Incompletezza o ambiguità dei requisiti espressi nel piano di lavoro	6
2.4.2	Incompletezza o ambiguità dei requisiti espressi nel piano di lavoro	7
3	Analisi dei requisiti	9
3.1	Analisi degli utenti	9
3.2	Casi d'uso	9
3.3	Lista delle user stories	9
	Epic 1. Gestione utenti	9
	US1 Login	9
	US2 Registrazione	9
3.4	Tracciamento dei requisiti	10
4	Introduzione Teorica	13
4.1	Aspetti Teorici	13
4.2	Tecnologie	13
4.3	Strumenti	13
5	Descrizione del Lavoro Svolto	15
5.1	TODO	15
6	Conclusioni	17
6.1	Consuntivo finale	17
6.2	Raggiungimento degli obiettivi	17
6.3	Requisiti soddisfatti	17
6.4	Rischi occorsi e mitigati	18
6.5	Valutazione personale	18
	Glossario	19

Bibliografia	21
--------------------	----

Elenco delle Figure

Figura 1 Logo Pat SRL	1
-----------------------------	---

Elenco delle Tabelle

Tabella 1	Rischio R01	6
Tabella 2	Rischio R02	7
Tabella 3	Tracciamento dei requisiti funzionali.	10
Tabella 4	Tracciamento dei requisiti di qualità.	10
Tabella 5	Tracciamento dei requisiti di vincolo.	11
Tabella 6	Riepilogo dei requisiti.	11
Tabella 7	Consuntivo orario finale.	17
Tabella 8	Rischi occorsi con la loro mitigazione.	18

Elenco dei Codici Sorgente

Codice 1	Codice d'esempio.	7
----------	------------------------	---

Capitolo 1

Introduzione

In questo capitolo descrivo l'azienda, introduco il progetto, e spiego le motivazioni che mi hanno portato a sceglierlo.

1.1 L'azienda

Pat SRL è un'azienda parte del Gruppo Zucchetti, vanta un'esperienza ultra trentennale nello sviluppo di soluzioni software destinate sia ad aziende private che a istituzioni pubbliche. L'azienda si posiziona come partner tecnologico specializzato nella progettazione di piattaforme per la gestione e l'automazione dei processi aziendali e dei servizi di assistenza e supporto.



Figura 1: Logo Pat SRL

1.2 Il progetto

Il progetto ha come obiettivo principale la riprogettazione e la sostituzione dell'attuale architettura dati utilizzata per la persistenza e il recupero delle informazioni all'interno dei prodotti aziendali.

Attualmente, l'impresa adotta una soluzione consolidata basata sul paradigma della persistenza poliglotta.

1 Introduzione

Tale architettura prevede l'utilizzo congiunto di due sistemi separati: PostgreSQL per la gestione dei dati strettamente relazionali ed Elasticsearch per l'indicizzazione dei documenti, la ricerca full-text, la gestione degli embedding vettoriali e le operazioni di filtraggio avanzato.

Sebbene questo approccio ibrido sia funzionale e ampiamente utilizzato, la divisione dei carichi di lavoro su motori di database differenti comporta diverse limitazioni architettoniche e operative:

- Denormalizzazione dei dati: la natura orientata ai documenti e non relazionale di Elasticsearch obbliga a replicare e denormalizzare i dati relazionali per consentire un filtraggio efficiente, aumentando la ridondanza.
- Overhead di sincronizzazione: il mantenimento della coerenza tra il database primario PostgreSQL e il motore di ricerca Elasticsearch richiede complesse pipeline di allineamento, esponendo il sistema a ritardi di sincronizzazione o disallineamenti.
- Mancanza di garanzie ACID globali: operando su sistemi separati, risulta complesso garantire l'atomicità e la consistenza transazionale durante l'inserimento o l'aggiornamento simultaneo di dati strutturati e vettoriali.

Per superare queste criticità, il progetto esplora la transizione verso un paradigma a database unificato. L'obiettivo è accentrare l'intero carico di lavoro su PostgreSQL sfruttando pgvector, un'estensione open-source che introduce il supporto nativo alla persistenza dei vettori di embedding e alle operazioni di algebra lineare direttamente all'interno dell'ecosistema relazionale.

Nello specifico, il nuovo sistema dovrà soddisfare i seguenti requisiti implementativi:

- Ingestion unificata: sviluppo di un modulo dedicato all'inserimento simultaneo di metadati relazionali e documenti non strutturati.
- Ottimizzazione degli indici: sfruttamento delle capacità di indicizzazione full-text native di PostgreSQL e creazione di indici vettoriali dedicati tramite pgvector per garantire l'efficienza scalabile della ricerca semantica.
- Integrazione relazionale: utilizzo di costrutti SQL per correlare dinamicamente i documenti e i vettori alle entità strutturate di dominio preesistenti nel gestionale.
- Ricerca Ibrida: implementazione di una logica di recupero che combini la precisione lessicale della ricerca testuale con la profondità concettuale della ricerca semantica, fondendo i risultati tramite l'algoritmo di Reciprocal Rank Fusion.

Al fine di validare rigorosamente l'efficacia di questa nuova architettura unificata, il sistema verrà sottoposto a una fase di benchmarking contro la soluzione attualmente in uso.

1 Introduzione

I test comparativi si concentreranno sulle seguenti metriche chiave:

- Latenza di interrogazione: misurazione dei tempi di risposta durante la ricerca testuale, semantica e ibrida.
- Velocità di indicizzazione: tempi necessari per l'elaborazione e l'inserimento a database di nuovi record complessi.
- Impatto sullo storage: analisi dello spazio su disco occupato dai dati e dai relativi indici.
- Complessità della pipeline: valutazione qualitativa della semplificazione architetturale.

1.3 Scelta del progetto

Ho scelto questo progetto per 3 ragioni principali:

1. Rilevanza dell'argomento: nell'informatica moderna, l'integrazione di funzionalità basate sull'Intelligenza Artificiale rappresenta un fattore competitivo e innovativo.
2. Centralità della manutenzione: il progetto permette di intervenire direttamente sulla fase più estesa, costosa e critica del ciclo di vita di un prodotto software aziendale.
3. Stack tecnologico all'avanguardia: offre l'opportunità di operare sul campo con strumenti e framework moderni.

1 Introduzione

Capitolo 2

Descrizione stage

In questo capitolo approfondisco l'organizzazione dello stage, il rapporto con l'azienda e svolgo l'analisi dei rischi.

2.1 Competenze da apprendere

Il tirocinio è strutturato per favorire lo sviluppo di un ventaglio di competenze trasversali, che spaziano dalla progettazione architettuale di alto livello fino all'implementazione tecnica.

Dal punto di vista metodologico, lo stage mira a consolidare le capacità di analisi dei requisiti, astrazione dei problemi complessi e progettazione di soluzioni algoritmiche generali e scalabili, promuovendo inoltre la collaborazione attiva con i tutor e gli stakeholder aziendali.

Sotto il profilo tecnico, il percorso formativo permetterà di acquisire e approfondire le seguenti tematiche:

- Sistemi AI e NLP: Comprensione dei fondamenti del Natural Language Processing e integrazione di modelli linguistici e framework associati.
- Database Avanzati: Padronanza nell'utilizzo di PostgreSQL non solo come database relazionale, ma come motore di Information Retrieval vettoriale tramite l'estensione pgvector.
- Progettazione della Ricerca Ibrida: Studio e valutazione delle tecnologie di indicizzazione. Per garantire un confronto equo e rigoroso con Elasticsearch, oltre alla ricerca full-text nativa di PostgreSQL, verrà esplorata l'integrazione di ParadeDB, una soluzione basata su Postgres che promette capacità di ricerca lessicale altrettanto evolute.
- Testing Comparativo: Acquisizione di metodologie per la conduzione di benchmark, definendo metriche di valutazione per misurare le performance e l'efficienza dei sistemi sviluppati.

2.2 Vincoli

Il progetto è soggetto a specifici vincoli architettureali volti a garantire la coerenza con gli obiettivi della ricerca. Il vincolo primario è l'adozione

2 Descrizione stage

esclusiva dell'estensione pgvector su ecosistema PostgreSQL per la gestione e l'interrogazione dei vettori di embedding.

2.3 Pianificazione

Lo stage si articola in 320 ore distribuite su otto settimane da 40 ore.

La pianificazione, derivata dal piano di lavoro, è la seguente:

1. Prima Settimana - Studio e analisi iniziale del nuovo e del vecchio stack tecnologico e setup (40 ore): studio delle tecnologie, setup dell'ambiente di lavoro locale e prove generiche;
2. Seconda Settimana - Analisi comparativa dettagliata di elastic search e Postgres con tentativo di modellazione di un sottoinsieme limitato del problema;
3. Terza Settimana - Studio del dominio, definizione dei requisiti e dei casi d'uso
4. Quarta settimana - Definizione dello schema relazionale e ottimizzazione tramite indici
5. Quinta settimana - Strutturazione del modulo di ingestion
6. Sesta settimana - Strutturazione del modulo API e integrazione dei framework di observability
7. Settima settimana - Testing e ottimizzazioni
8. Ottava settimana - Testing e ottimizzazioni

2.4 Analisi dei rischi

I rischi identificati per questo progetto sono classificati con un codice progressivo della forma **RN**, dove **N** è un numero intero incrementale che parte da 01, e decorati con una probabilità di occorrenza, un impatto e una strategia di mitigazione.

Ogni rischio è stato analizzato tenendo conto sia delle caratteristiche generali del progetto, sia delle specificità legate all'elaborazione OCR di documenti eterogenei.

2.4.1 Incompletezza o ambiguità dei requisiti espressi nel piano di lavoro

Campo	Descrizione
Codice	R01

2 Descrizione stage

Campo	Descrizione
Nome	Incompletezza o ambiguità dei requisiti espressi nel piano di lavoro
Descrizione	I requisiti descritti nel piano di lavoro possono risultare incompleti o ambigui, portando a implementazioni non coerenti con le aspettative del tutor aziendale
Mitigazione	I requisiti vengono analizzati e chiariti nelle prime fasi dello stage, producendo una specifica condivisa con il tutor. In caso di dubbi, si effettuano incontri chiarificatori prima di procedere con l'implementazione
Probabilità	Bassa
Impatto	Medio

Tabella 1: Rischio R01

2.4.2 Incompletezza o ambiguità dei requisiti espressi nel piano di lavoro

Campo	Descrizione
Codice	R02
Nome	Incompletezza o ambiguità dei requisiti espressi nel piano di lavoro
Descrizione	I requisiti descritti nel piano di lavoro possono risultare incompleti o ambigui, portando a implementazioni non coerenti con le aspettative del tutor aziendale
Mitigazione	I requisiti vengono analizzati e chiariti nelle prime fasi dello stage, producendo una specifica condivisa con il tutor. In caso di dubbi, si effet-

2 Descrizione stage

Campo	Descrizione
	tuano incontri chiarificatori prima di procedere con l'implementazione
Probabilità	Bassa
Impatto	Medio

Tabella 2: Rischio R02

Capitolo 3

Analisi dei requisiti

In questo capitolo effettuo l'analisi degli utenti, sviluppo le user stories e compongo la lista dei requisiti dividendoli per tipologia e necessità.

3.1 Analisi degli utenti

3.2 Casi d'uso

Nel contesto dello sviluppo agile...

3.3 Lista delle user stories

Epic 1. Gestione utenti

US1 Login

Descrizione: Come utente non autenticato, voglio poter fare il login per accedere alle funzionalità dell'applicativo.

Acceptance criteria:

1. L'utente deve poter inserire le proprie credenziali (email e password) in un modulo di login.
2. Se l'utente inserisce credenziali corrette, il sistema reindirizza l'utente alla dashboard.
3. Se l'utente inserisce credenziali errate, il sistema mostra un messaggio di errore.

US2 Registrazione

Descrizione: Come utente non autenticato, voglio potermi registrare per accedere alla piattaforma.

Acceptance criteria:

3 Analisi dei requisiti

1. L'utente deve poter compilare un modulo di registrazione con i campi richiesti (nome, cognome, email, password).
2. Il sistema effettua la verifica che l'utente non sia già registrato in piattaforma.
3. Dopo la verifica, il sistema invia una email all'utente che si sta registrando con un codice per poter attivare il proprio account.
4. Quando l'utente inserisce il codice ricevuto nella webapp, il suo account viene attivato e ha la possibilità di accedere.

3.4 Tracciamento dei requisiti

Ad ogni requisito è associato un codice costruito in base alle sue caratteristiche:

(F/Q/C)(M/D/O)R

F (*Functional*): definisce una funzione di un sistema o dei suoi componenti;

Q (*Qualitative*): rappresentano come il sistema deve essere per soddisfare i requisiti dello stakeholder;

C (*Constraint*): rappresentano dei vincoli o dei limiti che il sistema deve rispettare;

M (*Mandatory*): irrinunciabili per qualcuno degli stakeholder;

D (*Desirable*): non strettamente necessari ma a valore aggiunto riconoscibile;

O (*Optional*): relativamente utili oppure contrattabili anche in fasi avanzate del progetto;

R (*Requirement*): requisito

In Tabella 3, Tabella 4 e Tabella 5 sono riassunti i requisiti e il loro tracciamento con gli use case delineati in fase di analisi.

Codice	Descrizione	Fonti
--------	-------------	-------

Tabella 3: Tracciamento dei requisiti funzionali.

Codice	Descrizione	Fonti
--------	-------------	-------

Tabella 4: Tracciamento dei requisiti di qualità.

3 Analisi dei requisiti

Codice	Descrizione	Fonti
--------	-------------	-------

Tabella 5: Tracciamento dei requisiti di vincolo.

Di seguito, nella Tabella 6 ho inserito il riepilogo dei requisiti, suddivisi per tipologia e necessità.

Tipo	Mandatory	Desirable	Optional	Somma
Functional	Totale			

Tabella 6: Riepilogo dei requisiti.

3 Analisi dei requisiti

Capitolo 4

Introduzione Teorica

In questo capitolo approfondisco le basi teoriche rilevanti per la realizzazione del progetto, le tecnologie rilevanti per il progetto e relativi ruoli nella risoluzione dei problemi affrontati, quali strumenti sono stati adottati e altri strumenti adottati durante lo sviluppo.

4.1 Aspetti Teorici

4.2 Tecnologie

4.3 Strumenti

4 Introduzione Teorica

Capitolo 5

Descrizione del Lavoro Svolto

In questo capitolo approfondisco le problematiche affrontate nel concreto e le relative soluzioni.

5.1 TODO

Definire la struttura del capitolo.

5 Descrizione del Lavoro Svolto

Capitolo 6

Conclusioni

In questo capitolo traggio le conclusioni sul progetto.

6.1 Consuntivo finale

Una volta terminato il progetto ho redatto il consuntivo orario finale nella Tabella 7 che suddivide in maniera approssimata le ore dedicate alle varie fasi.

Fase	Ore
<i>Onboarding</i> del progetto	5
Analisi dei requisiti	30
...	...
Totale	320

Tabella 7: Consuntivo orario finale.

6.2 Raggiungimento degli obiettivi

6.3 Requisiti soddisfatti

Arrivato alla fine del progetto ho implementato...

)

6 Conclusioni

6.4 Rischi occorsi e mitigati

I rischi emersi durante lo stage sono riportati in Tabella 8.

Descrizione	Mitigazione
R1 – Descrizione del rischio	Soluzione

Tabella 8: Rischi occorsi con la loro mitigazione.

6.5 Valutazione personale

Glossario

Elasticsearch: Motore di analisi e ricerca distribuita. Funge da piattaforma di retrieval e salva dati strutturati, non strutturati e dati vettoriali. 5

LLM – Large Language Model: Modello di intelligenza artificiale addestrato su enormi quantità di testo per comprendere e generare linguaggio naturale, come GPT, Gemini o Mistral. Viene impiegato in compiti di analisi, estrazione di informazioni e generazione testuale. 5

Pgvector: Estensione per PostgreSQL, un database management system, che semplifica l'utilizzo dei vettori, consentendoti di archivarli, cercarli e indicizzarli direttamente nel tuo database relazionale. 5

RAG – Retrieval Augmented generation: Tecnica che permette ai LLM di reperire e incorporare informazioni da fonti di dati esterne.

Questo permette di recuperare informazioni rilevanti da database, documenti caricati, fonti web, ecc...

Il vantaggio principale è l'attualità delle risposte fornite dall'LLM e la possibilità di non dover usare documenti privati in fase di addestramento. 5

Bibliografia