

Università degli studi di Padova

DIPARTIMENTO DI MATEMATICA “TULLIO LEVI-CIVITA”

CORSO DI LAUREA IN INFORMATICA



**Valutazione di pgvector come
database unificato per RAG**

Tesi di laurea triennale

Relatore

Marco Zanella

Laureando

Davide Lorenzon

Matricola 2101075

I hate perfection. To be perfect is to be unable to improve any further.

— Kurotsuchi Mayuri

Ringraziamenti

Innanzitutto, vorrei esprimere la mia gratitudine al Prof. Marco Zanella relatore della mia tesi, per l'aiuto e il continuo sostegno fornitomi durante la stesura del lavoro.

Desidero ringraziare con affetto i miei genitori e i miei parenti per il sostegno e per essermi stati vicini durante gli anni di studio.

Ho desiderio di ringraziare poi i miei amici per tutti i bellissimi anni passati insieme.

Ci tengo infine a ringraziare i colleghi di Pat SRL e il tutor aziendale Davide Bastianetto per avermi dato l'opportunità di lavorare a questo progetto.

Padova, Settembre 2026

Davide Lorenzon

Sommario

Il presente documento descrive il lavoro svolto durante il periodo di stage curricolare, della durata di circa trecentoventi ore, dal laureando Davide Lorenzon presso l'azienda Pat SRL. Lo stage è stato condotto sotto la supervisione del tutor aziendale Davide Bastianetto, mentre il prof. Marco Zanella ha ricoperto il ruolo di tutor accademico.

Al centro di questo elaborato vi è la progettazione e lo sviluppo del modulo di retrieval di un sistema *RAG*. Questa architettura è oggi fondamentale poiché permette agli *LLM* di accedere a basi di conoscenza private e informazioni aggiornate senza la necessità di ricorrere a costosi processi di retraining, abbattendo drasticamente il rischio di allucinazioni da parte dell'Intelligenza Artificiale.

Lo scopo principale del progetto è valutare l'adeguatezza, la fattibilità tecnica e le performance dell'estensione *Pgvector* per PostgreSQL, impiegandola come database unificato per l'intera pipeline RAG. Nello specifico, l'obiettivo è verificare se tale tecnologia possa supportare efficacemente l'indicizzazione dei documenti, la ricerca ibrida (combinando ricerca full-text e semantica), l'applicazione di strategie di ranking avanzate e la correlazione relazionale con entità strutturate.

Per convalidare questa ipotesi e fornire una misura rigorosa della qualità del sistema, l'infrastruttura progettata verrà sistematicamente sottoposta a test comparativi contro una pipeline equivalente basata su *Elasticsearch*, tecnologia attualmente adottata all'interno dell'impresa.

L'utilità e il valore aggiunto di questa ricerca risiedono nella potenziale semplificazione dell'infrastruttura IT aziendale. Gestire dati relazionali, testuali e vettoriali all'interno di un unico ecosistema permetterebbe di superare il paradigma della persistenza poliglotta e dei workaround per implementare concetti relazionali come le relazioni tra entità, eliminando la necessità di mantenere sistemi separati. Questo approccio promette di abbattere l'overhead di sincronizzazione dei dati, ridurre i costi di manutenzione sistemistica e garantire transazioni più sicure. Sono previsti test comparativi tra il nuovo sistema e il sistema attualmente in uso.

Organizzazione del testo

- Il **primo capitolo** introduce l'azienda, il progetto e le motivazioni che mi hanno portato a sceglierlo;
- Il **secondo capitolo** descrive l'azienda, il progetto e l'organizzazione del lavoro, definendo gli obiettivi e analizzando i rischi;
- Il **terzo capitolo** descrive l'analisi dei requisiti del progetto, indicando un'analisi degli utenti, i casi d'uso e il tracciamento dei requisiti;
- Il **quarto capitolo** descrive le tecnologie esistenti per risolvere i problemi indicando gli aspetti teorici alla base, gli strumenti che sono stati scelti e con quali criteri;
- Il **quinto capitolo** descrive nel dettaglio le problematiche sorte nel concreto durante lo svolgimento del progetto;
- Il **sesto capitolo** raggruppa le conclusioni tratte dallo svolgimento del progetto.

Convenzioni tipografiche

Durante la stesura del testo ho scelto di adottare le seguenti convenzioni tipografiche: Le convenzioni tipografiche sono momentaneamente sospese e saranno riprese durante la stesura finale della tesi

- I blocchi di codice sono rappresentati nel seguente modo:

```
1  float Q_rsqr( float number ){
2      long i;
3      float x2, y;
4      const float threehalfs = 1.5F;
5      x2 = number * 0.5F;
6      y = number;
7      i = * (long * ) &y;
8      i = 0x5f3759df - (i>>1);
9      y = * (float * ) &i;
10     y = y * ( threehalfs - ( x2 * y * y ) );
11     //y = y * ( threehalfs - ( x2 * y * y ) );
12     return y;
13 }
```

Codice 1: Codice d'esempio.

Indice

1	Introduzione	1
1.1	L'azienda	1
1.2	Il progetto	1
1.3	Scelta del progetto	3
2	Descrizione stage	5
2.1	Competenze da apprendere	5
2.2	Vincoli	5
2.3	Pianificazione	6
2.4	Analisi dei rischi	6
3	Analisi dei requisiti	13
3.1	Analisi degli Utenti	13
3.1.1	Attori primari	13
3.1.2	Attori secondari	14
3.2	Casi d'uso	14
3.2.1	Struttura della scheda descrittiva	14
3.2.2	Lista dei Casi d'Uso	16
3.2.3		44
3.3	Tracciamento dei requisiti	44
4	Introduzione Teorica	47
4.1	Aspetti Teorici	47
4.2	Tecnologie	47
4.3	Strumenti	47
5	Descrizione del Lavoro Svolto	49
5.1	TODO	49
6	Conclusioni	51
6.1	Consuntivo finale	51
6.2	Raggiungimento degli obiettivi	51
6.3	Requisiti soddisfatti	51
6.4	Rischi occorsi e mitigati	52
6.5	Valutazione personale	52
	Glossario	53
	Bibliografia	55

Elenco delle Figure

Figura 1	Logo Pat SRL	1
Figura 2	Diagramma del caso d'uso: Ingestion di documenti	16
Figura 3	Diagramma del caso d'uso: Ingestion liste entità	17
Figura 4	Diagramma del caso d'uso: Ingestion lista entità	18
Figura 5	Diagramma del caso d'uso: Caricamento blocco entità ...	19
Figura 6	Diagramma del caso d'uso: Ingestion lista ticket	20
Figura 7	Diagramma del caso d'uso: Ingestion lista conversation item	21
Figura 8	Diagramma del caso d'uso: Ingestion lista attachments .	22
Figura 9	Diagramma del caso d'uso: Termina ingestion	23
Figura 10	Diagramma del caso d'uso: Ricerca su singola entità	24
Figura 11	Diagramma del caso d'uso: Inserimento query su singola entità	25
Figura 12	Diagramma del caso d'uso: Ricerca semantica	26
Figura 13	Diagramma del caso d'uso: Ricerca ibrida	27
Figura 14	Diagramma del caso d'uso: Ricerca ibrida con modello di re ranking	28
Figura 15	Diagramma del caso d'uso: Ricerca linked	30
Figura 16	Diagramma del caso d'uso: Inserimento query linked ...	31
Figura 17	Diagramma del caso d'uso: Ricerca linked semantica ...	32
Figura 18	Diagramma del caso d'uso: Ricerca linked ibrida	33
Figura 19	Diagramma del caso d'uso: Ricerca linked ibrida con modello di re ranking	34
Figura 20	Diagramma del caso d'uso: Avvia test	35
Figura 21	Diagramma del caso d'uso: Visualizza dashboard performance	36
Figura 22	Diagramma del caso d'uso: Visualizza metriche di performance	38
Figura 23	Diagramma del caso d'uso: Visualizzazione retrieval latency	39

Elenco delle Tabelle

Tabella 1	Tracciamento dei requisiti funzionali.	44
Tabella 2	Tracciamento dei requisiti di qualità.	44
Tabella 3	Tracciamento dei requisiti di vincolo.	44
Tabella 4	Riepilogo dei requisiti.	45
Tabella 5	Consuntivo orario finale.	51
Tabella 6	Rischi occorsi con la loro mitigazione.	52

Elenco dei Codici Sorgente

Codice 1	Codice d'esempio.	6
----------	------------------------	---

Capitolo 1

Introduzione

In questo capitolo descrivo l'azienda, introduco il progetto, e spiego le motivazioni che mi hanno portato a sceglierlo.

1.1 L'azienda

Pat SRL è un'azienda parte del Gruppo Zucchetti, vanta un'esperienza ultra trentennale nello sviluppo di soluzioni software destinate sia ad aziende private che a istituzioni pubbliche. L'azienda si posiziona come partner tecnologico specializzato nella progettazione di piattaforme per la gestione e l'automazione dei processi aziendali e dei servizi di assistenza e supporto.



Figura 1: Logo Pat SRL

1.2 Il progetto

Il progetto ha come obiettivo principale la riprogettazione e la sostituzione dell'attuale architettura dati utilizzata per la persistenza e il recupero delle informazioni all'interno dei prodotti aziendali.

Attualmente, l'impresa adotta una soluzione consolidata basata sul paradigma della persistenza poliglotta.

1 Introduzione

Tale architettura prevede l'utilizzo congiunto di due sistemi separati: PostgreSQL per la gestione dei dati strettamente relazionali ed Elasticsearch per l'indicizzazione dei documenti, la ricerca full-text, la gestione degli embedding vettoriali e le operazioni di filtraggio avanzato.

Sebbene questo approccio ibrido sia funzionale e ampiamente utilizzato, la divisione dei carichi di lavoro su motori di database differenti comporta diverse limitazioni architettoniche e operative:

- Denormalizzazione dei dati: la natura orientata ai documenti e non relazionale di Elasticsearch obbliga a replicare e denormalizzare i dati relazionali per consentire un filtraggio efficiente, aumentando la ridondanza e forzando a implementare in modo non ottimale funzioni come i join.
- Overhead di sincronizzazione: il mantenimento della coerenza tra il database primario PostgreSQL e il motore di ricerca Elasticsearch richiede complesse pipeline di allineamento, esponendo il sistema a ritardi di sincronizzazione o disallineamenti.
- Mancanza di garanzie ACID globali: operando su sistemi separati, risulta complesso garantire l'atomicità e la consistenza transazionale durante l'inserimento o l'aggiornamento simultaneo di dati strutturati e vettoriali.

Per superare queste criticità, il progetto esplora la transizione verso un paradigma a database unificato. L'obiettivo è accentrare l'intero carico di lavoro su PostgreSQL sfruttando pgvector, un'estensione open-source che introduce il supporto nativo alla persistenza dei vettori di embedding e alle operazioni di algebra lineare direttamente all'interno dell'ecosistema relazionale.

Nello specifico, il nuovo sistema dovrà soddisfare i seguenti requisiti implementativi:

- Ingestion: sviluppo di un modulo dedicato all'inserimento simultaneo di metadati relazionali e documenti non strutturati.
- Ottimizzazione degli indici: sfruttamento delle capacità di indicizzazione full-text native di PostgreSQL e creazione di indici vettoriali dedicati tramite pgvector per garantire l'efficienza scalabile della ricerca semantica.
- Integrazione relazionale: utilizzo di costrutti SQL per correlare dinamicamente i documenti e i vettori alle entità strutturate di dominio preesistenti nel gestionale.
- Ricerca Ibrida: implementazione di una logica di recupero che combini la precisione lessicale della ricerca testuale con la profondità concettuale della ricerca semantica, fondendo i risultati tramite l'algoritmo di Reciprocal Rank Fusion.

1 Introduzione

Al fine di validare rigorosamente l'efficacia di questa nuova architettura unificata, il sistema verrà sottoposto a una fase di benchmarking contro la soluzione attualmente in uso.

I test comparativi si concentreranno sulle seguenti metriche chiave:

- Latenza di interrogazione: misurazione dei tempi di risposta durante la ricerca testuale, semantica e ibrida.
- Velocità di indicizzazione: tempi necessari per l'elaborazione e l'inserimento a database di nuovi record complessi.
- Impatto sullo storage: analisi dello spazio su disco occupato dai dati e dai relativi indici.
- Complessità della pipeline: valutazione qualitativa della semplificazione architetturale.

1.3 Scelta del progetto

Ho scelto questo progetto per 3 ragioni principali:

1. Rilevanza dell'argomento: nell'informatica moderna, l'integrazione di funzionalità basate sull'Intelligenza Artificiale rappresenta un fattore competitivo e innovativo.
2. Centralità della manutenzione: il progetto permette di intervenire direttamente sulla fase più estesa, costosa e critica del ciclo di vita di un prodotto software aziendale.
3. Stack tecnologico all'avanguardia: offre l'opportunità di operare sul campo con strumenti e framework moderni.

1 Introduzione

Capitolo 2

Descrizione stage

In questo capitolo approfondisco l'organizzazione dello stage, il rapporto con l'azienda e svolgo l'analisi dei rischi.

2.1 Competenze da apprendere

Il tirocinio è strutturato per favorire lo sviluppo di un ventaglio di competenze trasversali, che spaziano dalla progettazione architettuale di alto livello fino all'implementazione tecnica.

Dal punto di vista metodologico, lo stage mira a consolidare le capacità di analisi dei requisiti, astrazione dei problemi complessi e progettazione di soluzioni algoritmiche generali e scalabili, promuovendo inoltre la collaborazione attiva con i tutor e gli stakeholder aziendali.

Sotto il profilo tecnico, il percorso formativo permetterà di acquisire e approfondire le seguenti tematiche:

- Sistemi AI e NLP: Comprensione dei fondamenti del Natural Language Processing e integrazione di modelli linguistici e framework associati.
- Database Avanzati: Padronanza nell'utilizzo di PostgreSQL non solo come database relazionale, ma come motore di Information Retrieval vettoriale tramite l'estensione pgvector.
- Progettazione della Ricerca Ibrida: Studio e valutazione delle tecnologie di indicizzazione. Per garantire un confronto equo e rigoroso con Elasticsearch, oltre alla ricerca full-text nativa di PostgreSQL, verrà esplorata l'integrazione di ParadeDB, una soluzione basata su Postgres che promette capacità di ricerca lessicale altrettanto evolute.
- Testing Comparativo: Acquisizione di metodologie per la conduzione di benchmark, definendo metriche di valutazione per misurare le performance e l'efficienza dei sistemi sviluppati.

2.2 Vincoli

Il progetto è soggetto a specifici vincoli architettureali volti a garantire la coerenza con gli obiettivi della ricerca. Il vincolo primario è l'adozione

2 Descrizione stage

esclusiva dell'estensione pgvector su ecosistema PostgreSQL per la gestione e l'interrogazione dei vettori di embedding.

2.3 Pianificazione

Lo stage si articola in 320 ore distribuite su otto settimane da 40 ore.

La pianificazione, derivata dal piano di lavoro, è la seguente:

1. Prima Settimana - Studio e analisi iniziale del nuovo e del vecchio stack tecnologico e setup (40 ore): studio delle tecnologie, setup dell'ambiente di lavoro locale e prove generiche;
2. Seconda Settimana - Analisi comparativa dettagliata di elastic search e Postgres con tentativo di modellazione di un sottoinsieme limitato del problema;
3. Terza Settimana - Studio del dominio, definizione dei requisiti e dei casi d'uso e definizione dello schema relazionale
4. Quarta settimana - Studio del dominio, definizione dei requisiti e dei casi d'uso e definizione dello schema relazionale e ottimizzazione tramite indici
5. Quinta settimana - Strutturazione del modulo di ingestion
6. Sesta settimana - Strutturazione del modulo API e integrazione del framework di observability
7. Settima settimana - Testing e ottimizzazioni
8. Ottava settimana - Testing e ottimizzazioni

2.4 Analisi dei rischi

I rischi identificati per questo progetto sono classificati con un codice progressivo della forma **RN**, dove **N** è un numero intero incrementale che parte da 01, e decorati con una probabilità di occorrenza, un impatto e una strategia di mitigazione.

Ogni rischio è stato analizzato tenendo conto della complessità di comprendere i casi d'uso del sistema di paragone Elastic, delle sue scelte implementative dovute allo stack tecnologico e dalla comprensione degli interessi sperimentativi dell'impresa.

Codice : R01

Incompletezza o ambiguità dei requisiti

- **Descrizione:**

I requisiti descritti nel piano di lavoro possono risultare incompleti o ambigui, portando a implementazioni non coerenti con le aspettative aziendali.

- **Mitigazione:**

I requisiti vengono analizzati e chiariti prima delle attività di codifica. Viene data priorità ad attività di studio teorico dello stack tecnologico e alla realizzazione di prototipi a diversi livelli di complessità. Sono previsti incontri iterativi con il tutor per definire chiaramente i confini del progetto e le interfacce di comunicazione.

- **Probabilità:** Medio-Alta

- **Impatto:** Medio

Codice : R02

Sovradimensionamento del progetto rispetto alle tempistiche

- **Descrizione:**

Le attività previste potrebbero rivelarsi eccessive rispetto al monte ore disponibile e alle tempistiche di apprendimento, con il rischio di non completare tutti gli obiettivi prefissati.

- **Mitigazione:**

Le attività sono suddivise per priorità (requisiti obbligatori, desiderabili, opzionali). In caso di ritardi o imprevisti strutturali, solo le attività a priorità inferiore e non vincolanti per lo scopo principale del progetto subiranno ridimensionamenti.

- **Probabilità:** Media

- **Impatto:** Alto

2 Descrizione stage

Codice : R03

Difficoltà nel coordinamento interno

- **Descrizione:**

La comunicazione con il tutor aziendale o con gli stakeholder potrebbe risultare discontinua, rallentando il processo decisionale tecnico e causando incomprensioni.

- **Mitigazione:**

Vengono pianificati incontri periodici di allineamento, accompagnati da aggiornamenti asincroni frequenti sullo stato di avanzamento. Eventuali blocchi tecnici vengono segnalati tempestivamente senza attendere la riunione successiva.

- **Probabilità:** Media

- **Impatto:** Alto

Codice : R04

Curva di apprendimento delle tecnologie

- **Descrizione:**

L'assimilazione delle tecnologie necessarie (es. pgvector, framework NLP) potrebbe richiedere un tempo di studio superiore alle stime iniziali.

- **Mitigazione:**

Le prime settimane dello stage includono ore dedicate esplicitamente allo studio della documentazione ufficiale, alla schematizzazione delle architetture e alla realizzazione di proof of concept isolati.

- **Probabilità:** Bassa

- **Impatto:** Medio

Codice : R05

Incompatibilità o difficoltà di integrazione con il sistema legacy

- **Descrizione:**

Il modulo realizzato dovrà essere testato in un ambiente paragonabile a quello di produzione; potrebbero emergere attriti o incompatibilità nell'interfacciamento con il sistema esistente.

- **Mitigazione:**

Confronto continuo con il team di sviluppo per comprendere a fondo i contratti delle interfacce. Adozione del design pattern «Adapter» fin dalle prime fasi di progettazione per disaccoppiare la logica del nuovo sistema da quella preesistente.

- **Probabilità:** Media

- **Impatto:** Medio

Codice : R06

Saturazione delle risorse durante i benchmark

- **Descrizione:**

L'esecuzione dei test comparativi su volumi di dati enterprise (fino a 500.000 record) potrebbe causare la saturazione delle risorse hardware dell'ambiente di test, falsando le metriche o causando crash di sistema.

- **Mitigazione:**

I test verranno eseguiti in modo incrementale su dataset di dimensioni crescenti.

Verrà implementato un monitoraggio attivo delle risorse tramite il framework di observability per individuare eventuali memory leak o configurazioni sub-ottimali degli indici vettoriali prima dei test massivi.

- **Probabilità:** Media

- **Impatto:** Alto

Codice : R07

Rappresentatività dei dati di test e accesso limitato alla produzione

- **Descrizione:**

L'utilizzo di dati generati appositamente per le fasi di test locali, reso necessario dai vincoli di privacy aziendale, potrebbe non riflettere a pieno la reale complessità e varianza del dominio. Questa discrepanza rischia di alterare la valutazione dell'accuratezza degli embedding e di non far emergere casistiche limite verosimili, portando a possibili divergenze di performance tra l'ambiente di sviluppo e le aspettative finali.

- **Mitigazione:**

La validazione seguirà un approccio a due fasi: l'architettura dovrà innanzitutto superare i benchmark di riferimento in ambiente locale utilizzando dei dati di test.

A valle di questo consolidamento, le misurazioni definitive verranno eseguite sui dati reali operando esclusivamente all'interno dei server proprietari aziendali, nel pieno rispetto delle direttive di sicurezza.

- **Probabilità:** Alta

- **Impatto:** Medio

Codice : R08

Difficoltà nella valutazione oggettiva dei risultati di Retrieval

- **Descrizione:**

L'assenza di metriche standardizzate o un'errata interpretazione dei risultati potrebbe portare a conclusioni soggettive, rendendo impossibile valutare se il nuovo sistema eguaglia o supera la soluzione precedente.

- **Mitigazione:**

Le metriche di valutazione quantitativa verranno definite esplicitamente nella fase di analisi dei requisiti.

Queste corrispondono alle metriche attualmente usate per la valutazione del sistema attuale

È inoltre previsto un caso d'uso specifico per la produzione di una dashboard di monitoraggio, con criteri di accettazione e soglie minime di qualità chiaramente prestabiliti.

- **Probabilità:** Media

- **Impatto:** Alto

Codice : R09

Sbilanciamento metodologico nel confronto

- **Descrizione:**

Elasticsearch è un motore di ricerca nativo con analizzatori linguistici avanzati, mentre PostgreSQL nasce come RDBMS. Un set di test limitato rischierebbe di favorire asimmetricamente una tecnologia rispetto all'altra, invalidando l'equità del benchmark.

- **Mitigazione:**

Il set di query di test verrà progettato per essere eterogeneo e rappresentativo dei reali casi d'uso aziendali. Includerà intenzionalmente sia scenari che valorizzano PostgreSQL, sia scenari che valorizzano Elasticsearch.

- **Probabilità:** Alta

- **Impatto:** Alto

Codice : R10

Dispersione del perimetro di test su tecnologie alternative

- **Descrizione:**

L'evoluzione rapida del panorama RAG solleva l'interrogativo su alternative tecnologiche, come Open-Search.

La loro valutazione va fuori dagli interessi dell'impresa per questo specifico tirocinio e rischia di aggiungere attività di studio non utili alla realizzazione del progetto.

- **Mitigazione:**

I confini del tirocinio sono rigidamente circoscritti al confronto diretto tra la soluzione in uso, basata su Elasticsearch, e le tecnologie che l'impresa vuole valutare, PostgreSQL + pgvector.

Eventuali tecnologie alternative verranno affrontate esclusivamente a livello teorico.

- **Probabilità:** Bassa

- **Impatto:** Medio

Codice : R11

Sovrapposizione tra le performance di Retrieval e Generation

- **Descrizione:**

L'architettura RAG si compone di due fasi: la fase di retrieval che si occupa del recupero di informazioni e la generazione della risposta. Nel sistema attuale solo la parte di retrieval e ingestion di documenti è collegata strettamente a Elasticsearch, le altre parti del sistema sono gestite in Python puro.

- **Mitigazione:**

Vengono posti dei rigidi confini sul sistema da implementare. L'implementazione, l'analisi e il testing si concentreranno unicamente sulla componente di Retriever e sul relativo modulo di ingestion. La valutazione ignorerà la qualità dell'output generativo dell'LLM, misurando esclusivamente la pertinenza dei documenti e la velocità di recupero.

- **Probabilità:** Bassa

- **Impatto:** Alto

Capitolo 3

Analisi dei requisiti

In questo capitolo effettuo l'analisi degli utenti, sviluppo le user stories e compongo la lista dei requisiti dividendoli per tipologia e necessità.

3.1 Analisi degli Utenti

Al fine di modellare correttamente le interazioni e definire i confini del sistema oggetto del tirocinio, è necessario individuare gli attori coinvolti. In accordo con le metodologie dell'ingegneria del software, gli attori comprendono sia gli utenti umani sia i sistemi software esterni che interagiscono direttamente con l'architettura.

Gli attori sono classificati in due categorie:

- Attori primari: entità che avviano i casi d'uso e richiedono un servizio al sistema.
- Attori secondari: servizi o sistemi esterni invocati dal sistema per completare una specifica elaborazione.

3.1.1 Attori primari

- **Companion**

Con il termine **Companion** si identifica l'applicativo aziendale di Intelligenza Artificiale di livello superiore. Questo attore software è il client principale: è il software applicativo reale all'interno del quale il modulo sviluppato durante lo stage verrebbe integrato a scopo esplorativo.

Companion interagisce con il sistema tramite chiamate api.

Companion interagisce con il sistema per due scopi fondamentali: delegare l'ingestione dei dati documentali e interrogare la base di conoscenza tramite la pipeline RAG per ottenere il contesto necessario alla generazione delle risposte.

3 Analisi dei requisiti

- **Supervisore**

Rappresenta l'utente tecnico qualificato. Il suo ruolo è quello di interfacciarsi con il sistema a scopo di analisi, validazione e benchmarking. Il Supervisore avvia i test prestazionali, monitora l'infrastruttura e raccoglie le metriche necessarie per valutare e comparare le prestazioni del nuovo database unificato rispetto alla soluzione correntemente usata in produzione.

3.1.2 Attori secondari

- **Modello di Embedding**

Si tratta di un attore software esterno che fornisce il servizio di vettorizzazione. Il sistema oggetto dello stage invoca questo attore delegandogli il compito computazionale di trasformare i chunk di testo grezzo in vettori numerici, questi vettori verranno poi usati per popolare l'indice vettoriale e per l'esecuzione della ricerca semantica.

3.2 Casi d'uso

In questa sezione vengono definiti i casi d'uso del sistema. Ogni caso d'uso è univocamente identificato da una sigla progressiva (es. **UC-X**) ed è corredato da una scheda descrittiva analitica. Gli attori menzionati fanno diretto riferimento alle definizioni riportate nella sezione Capitolo 3.1.

3.2.1 Struttura della scheda descrittiva

Ciascun caso d'uso è documentato attraverso le informazioni elencate nella tabella seguente. Al fine di mantenere la documentazione concisa, i campi non rilevanti o non applicabili a uno specifico scenario verranno omessi.

Campo	Descrizione
Grafico UML	Rappresentazione visiva dello scenario tramite diagramma UML dei casi d'uso.
Attore principale	Entità esterna che avvia l'interazione con il sistema per raggiungere un obiettivo specifico.
Attore secondario	Sistema o servizio esterno invocato dal sistema per completare una determinata funzionalità.

3 Analisi dei requisiti

Campo	Descrizione
Scenario principale	La sequenza nominale di operazioni necessaria per portare a compimento il caso d'uso senza interruzioni.
Precondizioni	Stato del sistema o requisiti che devono essere necessariamente soddisfatti prima dell'avvio del caso d'uso.
Postcondizioni	Stato del sistema o modifiche persistenti che si verificano al termine della corretta esecuzione dello scenario principale.
Scenario alternativo	Flussi di esecuzione secondari che deviano dallo scenario base, tipicamente per gestire anomalie, errori o percorsi non standard.
Inclusioni	Relazione verso un altro caso d'uso, il cui comportamento è obbligatoriamente e incondizionatamente incorporato nello scenario corrente.
Estensioni	Relazione che introduce un comportamento opzionale o alternativo, attivato unicamente al verificarsi di specifiche condizioni.
Specializzazioni	Varianti strutturali del caso d'uso generale. I casi d'uso specializzati sono tra loro mutualmente esclusivi ed ereditano i comportamenti dello scenario base.
Trigger	L'evento, l'azione o la condizione scatenante che innesci l'esecuzione del caso d'uso.

3 Analisi dei requisiti

3.2.2 Lista dei Casi d'Uso

UC01: Ingestion di documenti




Figura 2: Diagramma del caso d'uso: Ingestion di documenti

- **Attore principale:** Companion
- **Precondizioni:**
 - Il sistema è attivo
 - Nel sistema non ci sono sessioni di ingestion di documenti attive
- **Postcondizioni:**
 - Il sistema ha salvato le informazioni ricevute
 - Il sistema ha salvato gli embedding relativi ai dati
 - Il sistema ha salvato le informazioni di lingua relative ai dati
 - Il sistema ha reso le informazioni disponibili per la ricerca
- **Scenario principale:**
 1. Companion avvia il processo di ingestion dei dati → UC01.1
 2. Companion carica le liste di entità → UC01.2
 3. Companion termina il processo di ingestion → UC01.3
 4. Companion viene notificato del corretto salvataggio dei dati.
- **Inclusioni:**
 - UC01.1
 - UC01.2
 - UC01.3
- **Trigger:** Companion vuole caricare dei documenti sul sistema

UC01.1: Avvia ingestion

- **Attore principale:** Companion

3 Analisi dei requisiti

- **Precondizioni:**
 - Il sistema è attivo
 - Nel sistema non ci sono sessioni di ingestion di documenti attive
- **Postcondizioni:**
 - Nel sistema è attiva una sessione di ingestion di documenti
- **Scenario principale:**
 1. Companion chiede di avviare una sessione di ingestion
 2. Il sistema avvia la sessione di ingestion
 3. Companion viene notificato della corretta apertura del sistema

UC01.2: Ingestion liste entità

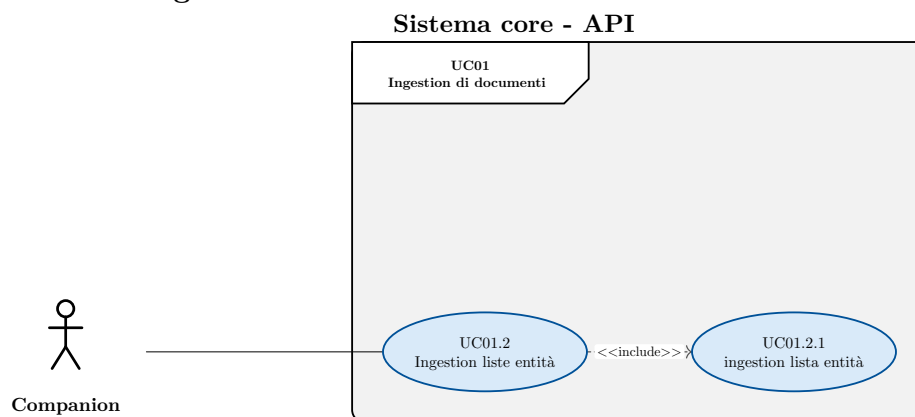


Figura 3: Diagramma del caso d'uso: Ingestion liste entità

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è attiva una sessione di ingestion
- **Postcondizioni:**
 - Il sistema ha salvato le informazioni relative alle liste di entità
 - Il sistema ha salvato gli embedding relativi alle liste di entità
 - Il sistema ha salvato le informazioni di lingua relative alle liste di entità
- **Scenario principale:**
 1. Companion carica le liste di entità
 - 1.1. Companion carica una lista di entità → UC01.2.1
- **Inclusioni:**
 - UC01.2.1

3 Analisi dei requisiti

UC01.2.1: Ingestion lista entità




Figura 4: Diagramma del caso d'uso: Ingestion lista entità

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è attiva una sessione di ingestion
- **Postcondizioni:**
 - Il sistema ha salvato le informazioni relative alla lista di entità
 - Il sistema ha salvato gli embedding relativi alla lista di entità
 - Il sistema ha salvato le informazioni di lingua relative alla lista di entità
- **Scenario principale:**
 1. Companion carica la lista di entità
 - 1.1. Companion carica un blocco di entità → UC01.2.1.1
- **Inclusioni:**
 - UC01.2.1.1
- **Specializzazioni:**
 - UC01.2.2
 - UC01.2.3
 - UC01.2.4

3 Analisi dei requisiti

UC01.2.1.1: Caricamento blocco entità

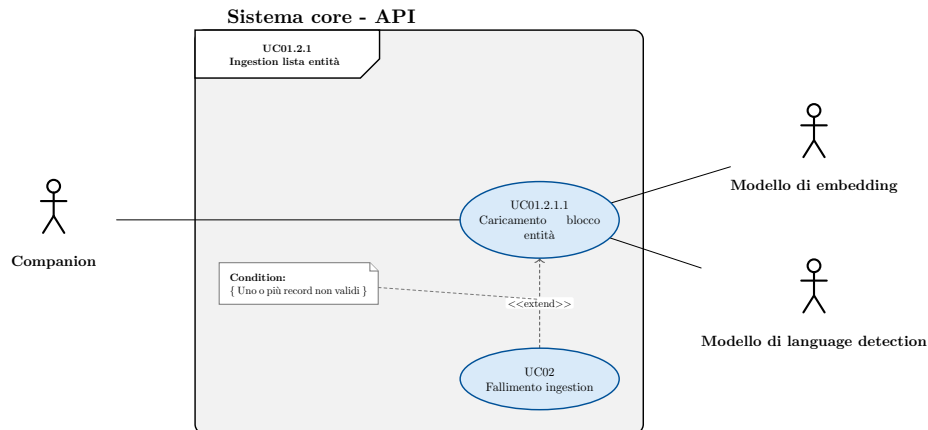


Figura 5: Diagramma del caso d'uso: Caricamento blocco entità

- **Attore principale:** Companion
- **Attore secondario:**
 - Modello di embedding
 - Modello di language detection
- **Precondizioni:**
 - Il processo di caricamento lista di entità è in corso
- **Postcondizioni:**
 - Il sistema ha salvato le informazioni relative al blocco di entità
 - Il sistema ha salvato gli embedding relativi al blocco di entità
 - Il sistema ha salvato le informazioni di lingua relative al blocco di entità
- **Scenario principale:**
 1. Companion carica un blocco di entità
 2. Il sistema salva i dati dei entità
 3. Il sistema calcola l'embedding da associare ai chunk di testo usando il modello di embedding
 4. Il sistema rileva le informazioni di lingua da applicare ai chunk
 - 4.1. Il sistema può usare l'informazione linguistica presente nei dati caricati
 - 4.2. Il sistema può usare un modello language detection
 5. Il sistema associa gli embedding al relativo frammento di testo
 6. Il sistema associa la lingua al relativo frammento di testo
 7. Il sistema salva il blocco di entità
- **Scenari alternativi:**
 - Uno o più record del blocco non sono validi → UC02
- **Estensioni:**
 - UC02

UC01.2.2: Ingestione lista ticket

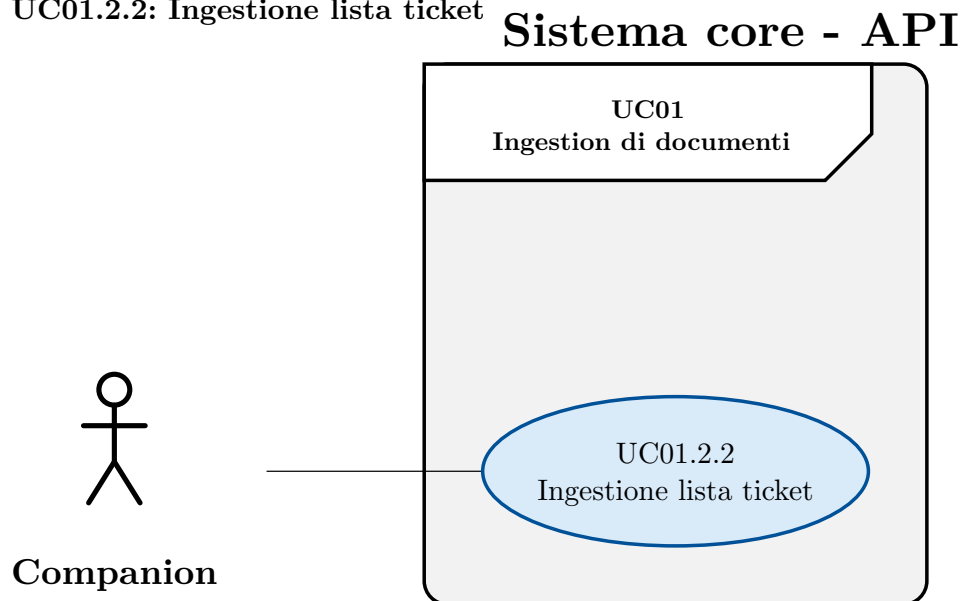


Figura 6: Diagramma del caso d'uso: Ingestione lista ticket

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è attiva una sessione di ingestion
- **Postcondizioni:**
 - Il sistema ha salvato le informazioni relative alla lista di ticket
 - Il sistema ha salvato gli embedding relativi alla lista di ticket
 - Il sistema ha salvato le informazioni di lingua relative alla lista di ticket
- **Scenario principale:**
 1. Companion carica la lista dei ticket




Figura 7: Diagramma del caso d'uso: Ingestione lista conversation item

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è attiva una sessione di ingestion
- **Postcondizioni:**
 - Il sistema ha salvato le informazioni relative alla lista di conversation item
 - Il sistema ha salvato gli embedding relativi alla lista di conversation item
 - Il sistema ha salvato le informazioni di lingua relative alla lista di conversation item
- **Scenario principale:**
 1. Companion carica la lista dei conversation item
- **Inclusioni:**

UC01.2.4: Ingestione lista attachments

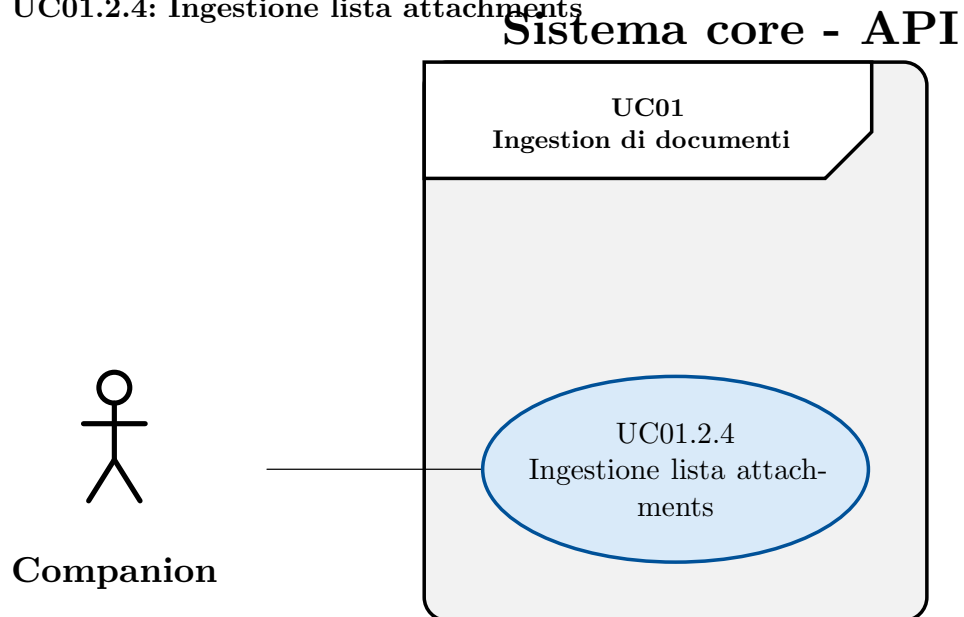


Figura 8: Diagramma del caso d'uso: Ingestione lista attachments

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è attiva una sessione di ingestion
- **Postcondizioni:**
 - Il sistema ha salvato le informazioni relative alla lista di attachment
 - Il sistema ha salvato gli embedding relativi alla lista di attachment
 - Il sistema ha salvato le informazioni di lingua relative alla lista di attachment
- **Scenario principale:**
 1. Companion carica la lista dei attachment
- **Inclusioni:**

UC01.3: Termina ingestion




Figura 9: Diagramma del caso d'uso: Termina ingestion

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è attiva una sessione di ingestion
 - Nel sistema i dati inseriti sono stati resi disponibili per la ricerca
- **Postcondizioni:**
 - Nel sistema viene chiusa la sessione di ingestion
- **Scenario principale:**
 1. Companion chiede il termine della sessione di ingestion
 2. Il sistema rende i dati disponibili per la ricerca
 3. Il sistema chiude la sessione di ingestion
- **Scenari alternativi:**
 - Nel sistema è ancora in corso l'elaborazione di dati → UC01.3.1
- **Estensioni:**
 - UC01.3.1

UC01.3.1: Errore termine ingestion

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è attiva una sessione di ingestion
 - Nel sistema i dati inseriti sono stati resi disponibili per la ricerca
- **Postcondizioni:**
 - Nel sistema rimane attiva la sessione di ingestion
 - Companion viene notificato dell'errore

3 Analisi dei requisiti

- **Scenario principale:**

1. Companion chiede il termine della sessione di ingestion
2. Il sistema rileva che è ancora in corso l'elaborazione dei dati
3. Companion riceve una notifica esplicativa dell'errore

UC02: Fallimento ingestion

- **Attore principale:** Companion

- **Precondizioni:**

- Il processo di caricamento lista di entità è in corso

- **Postcondizioni:**

- Il sistema non ha salvato i record non validi
- Companion riceve un messaggio di errore esplicativo

- **Scenario principale:**

1. Companion carica un blocco di entità
2. Rileva degli errori relativi a uno o più record del blocco
3. Companion riceve un errore esplicativo relativo ai record che hanno generato errori

UC03: Ricerca su singola entità




Figura 10: Diagramma del caso d'uso: Ricerca su singola entità

- **Attore principale:** Companion

- **Precondizioni:**

- Il sistema è attivo

- **Postcondizioni:**

- Companion ha ricevuto i risultati della ricerca

3 Analisi dei requisiti

- **Scenario principale:**
 1. Companion inserisce una query → UC03.1
 2. Il sistema valida la query
 3. Il sistema esegue la query
 4. Companion riceve i risultati → UC03.2
- **Scenari alternativi:**
 - Errore durante la ricerca → UC05
- **Inclusioni:**
 - UC03.1
 - UC03.2
- **Estensioni:**
 - UC04
- **Specializzazioni:**
 - UC03.3
 - UC03.4
 - UC03.5
- **Trigger:** Companion vuole eseguire una ricerca su una singola entità

UC03.1: Inserimento query su singola entità




Figura 11: Diagramma del caso d'uso: Inserimento query su singola entità

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è in corso una ricerca su una singola entità
- **Postcondizioni:**
 - Il sistema ha elaborato la query
- **Scenario principale:**
 1. Companion inserisce la query di ricerca

3 Analisi dei requisiti

- **Scenari alternativi:**
 - Errore query non valida → UC04
- **Estensioni:**
 - UC04

UC03.2: Ricezione risultati ricerca singola entità

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è in corso una ricerca su singola entità
 - Il sistema ha eseguito la query
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca
- **Scenario principale:**
 1. Il sistema ritorna la lista dei risultati prodotti dalla ricerca
 2. Companion riceve i risultati della ricerca

UC03.3: Ricerca full text

- **Attore principale:** Companion
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca.
- **Scenario principale:**
 1. Companion inserisce una query → UC03.1
 2. Il sistema esegue la query valutando la pertinenza in base alla ricerca full text
 3. Il sistema può ottimizzare la ricerca basandosi sulla lingua
 4. Companion riceve i risultati → UC03.2
- **Trigger:** Companion vuole eseguire una ricerca full-text su una singola entità

UC03.4: Ricerca semantica




Figura 12: Diagramma del caso d'uso: Ricerca semantica

3 Analisi dei requisiti

- **Attore principale:** Companion
- **Attore secondario:** Modello di embedding
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca.
- **Scenario principale:**
 1. Companion inserisce una query → UC03.1
 2. Il sistema esegue la query valutando la pertinenza in base alla ricerca semantica
 3. Companion riceve i risultati → UC03.2
- **Trigger:** Companion vuole eseguire una ricerca semantica su una singola entità

UC03.5: Ricerca ibrida




Figura 13: Diagramma del caso d'uso: Ricerca ibrida

- **Attore principale:** Companion
- **Attore secondario:** Modello di embedding
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca.
- **Scenario principale:**
 1. Companion inserisce una query → UC03.1
 2. Il sistema esegue la query valutando la pertinenza in base alla ricerca semantica
 3. Il sistema esegue la query valutando la pertinenza in base alla ricerca full-text
 4. Il sistema fonde i risultati
 5. Companion riceve i risultati → UC03.2
- **Specializzazioni:**
 - UC03.5.1
 - UC03.5.2

3 Analisi dei requisiti

- **Trigger:** Companion vuole eseguire una ricerca su una singola entità

UC03.5.1: Ricerca ibrida con rrf

- **Attore principale:** Companion
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca.
- **Scenario principale:**
 1. Companion inserisce una query → UC03.1
 2. Il sistema esegue la query valutando la pertinenza in base alla ricerca semantica
 3. Il sistema esegue la query valutando la pertinenza in base alla ricerca full-text
 4. Il sistema fonde i risultati tramite RRF
 5. Companion riceve i risultati → UC03.2
- **Trigger:** Companion vuole eseguire una ricerca su una singola entità

UC03.5.2: Ricerca ibrida con modello di re ranking




Figura 14: Diagramma del caso d'uso: Ricerca ibrida con modello di re ranking

- **Attore principale:** Companion
- **Attore secondario:** Modello di re-ranking
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca.

3 Analisi dei requisiti

- **Scenario principale:**
 1. Companion inserisce una query → UC03.1
 2. Il sistema esegue la query valutando la pertinenza in base alla ricerca semantica
 3. Il sistema esegue la query valutando la pertinenza in base alla ricerca full-text
 4. Il sistema fonde i risultati affidandosi a un modello di re-ranking esterno
 5. Companion riceve i risultati → UC03.2
- **Trigger:** Companion vuole eseguire una ricerca su una singola entità

UC04: Inserimento query su singola entità non valida

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è in corso una ricerca su una singola entità
 - Companion ha inserito una query non valida
- **Postcondizioni:**
 - Companion riceve notifica esplicita dell'errore
- **Scenario principale:**
 1. Il sistema rileva la non validità della query
 2. Il sistema interrompe la ricerca
 3. Companion riceve un messaggio d'errore esplicativo

UC05: Errore ricerca su singola entità

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è in corso una ricerca su una singola entità
 - Nel sistema si è verificato un errore durante la ricerca
- **Postcondizioni:**
 - Companion riceve notifica esplicita dell'errore
- **Scenario principale:**
 1. Il sistema interrompe la ricerca
 2. Companion riceve un messaggio d'errore esplicativo

3 Analisi dei requisiti

UC06: Ricerca linked




Figura 15: Diagramma del caso d'uso: Ricerca linked

- **Attore principale:** Companion
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca.
- **Scenario principale:**
 1. Companion inserisce una query → UC06.1
 2. Il sistema valida la query
 3. Il sistema esegue la query
 4. Companion riceve i risultati → UC06.2
- **Scenari alternativi:**
 - Errore durante la ricerca → UC08
- **Inclusioni:**
 - UC06.1
 - UC06.2
- **Estensioni:**
 - UC08
- **Specializzazioni:**
 - UC06.3
 - UC06.4
 - UC06.5
- **Trigger:** Companion vuole eseguire una ricerca su tutte le entità

UC06.1: Inserimento query linked




Figura 16: Diagramma del caso d'uso: Inserimento query linked

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è in corso una ricerca linked
- **Postcondizioni:**
 - Il sistema ha elaborato la query
- **Scenario principale:**
 1. Companion inserisce la query di ricerca
- **Scenari alternativi:**
 - Errore query non valida → UC07
- **Estensioni:**
 - UC07

UC06.2: Ricezione risultati ricerca linked

- **Attore principale:** Companion
- **Precondizioni:**
 1. Il sistema ha eseguito la query
- **Postcondizioni:**
 1. Companion ha ricevuto i risultati della ricerca
- **Scenario principale:**
 1. Companion ritorna la lista dei risultati prodotti dalla ricerca

UC06.3: Ricerca linked full text

- **Attore principale:** Companion

3 Analisi dei requisiti

- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca.
- **Scenario principale:**
 1. Companion inserisce una query → UC06.1
 2. Il sistema esegue la query valutando la pertinenza in base alla ricerca full text
 3. Il sistema può ottimizzare la ricerca basandosi sulla lingua
 4. Companion riceve i risultati → UC06.2
- **Trigger:** Companion vuole eseguire una ricerca su tutte le entità

UC06.4: Ricerca linked semantica




Figura 17: Diagramma del caso d'uso: Ricerca linked semantica

- **Attore principale:** Companion
- **Attore secondario:** Modello di embedding
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca.
- **Scenario principale:**
 1. Companion inserisce una query → UC06.1
 2. Il sistema esegue la query valutando la pertinenza in base alla ricerca semantica
 3. Companion riceve i risultati → UC06.2
- **Trigger:** Companion vuole eseguire una ricerca su tutte le entità

UC06.5: Ricerca linked ibrida




Figura 18: Diagramma del caso d'uso: Ricerca linked ibrida

- **Attore principale:** Companion
- **Attore secondario:** Modello di embedding
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca.
- **Scenario principale:**
 1. Companion inserisce una query → UC06.1
 2. Il sistema esegue la query valutando la pertinenza in base alla ricerca semantica
 3. Il sistema esegue la query valutando la pertinenza in base alla ricerca full-text
 4. Il sistema fonde i risultati
 5. Companion riceve i risultati → UC06.2
- **Trigger:** Companion vuole eseguire una ricerca su tutte le entità

UC06.5.1: Ricerca linked ibrida con rrf

- **Attore principale:** Companion
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca.
- **Scenario principale:**
 1. Companion inserisce una query → UC06.1
 2. Il sistema esegue la query valutando la pertinenza in base alla ricerca semantica
 3. Il sistema esegue la query valutando la pertinenza in base alla ricerca full-text
 4. Il sistema fonde i risultati tramite RRF
 5. Companion riceve i risultati → UC06.2

3 Analisi dei requisiti

- **Trigger:** Companion vuole eseguire una ricerca su tutte le entità

UC06.5.2: Ricerca linked ibrida con modello di re ranking

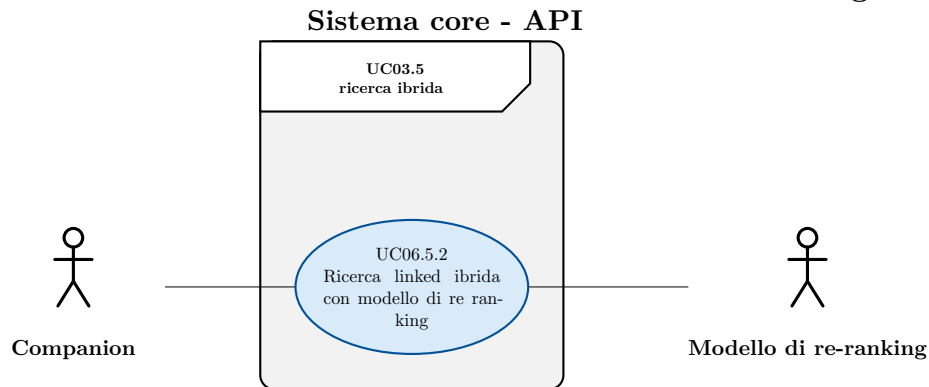


Figura 19: Diagramma del caso d'uso: Ricerca linked ibrida con modello di re ranking

- **Attore principale:** Companion
- **Attore secondario:** Modello di re-ranking
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Companion ha ricevuto i risultati della ricerca.
- **Scenario principale:**
 1. Companion inserisce una query → UC06.1
 2. Il sistema esegue la query valutando la pertinenza in base alla ricerca semantica
 3. Il sistema esegue la query valutando la pertinenza in base alla ricerca full-text
 4. Il sistema fonde i risultati tramite un modello di re-ranking
 5. Companion riceve i risultati → UC06.2
- **Trigger:** Companion vuole eseguire una ricerca su una singola entità

UC07: Inserimento query linked non valida

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è in corso una ricerca su una singola entità
 - Companion ha inserito una query non valida
- **Postcondizioni:**
 - Companion riceve notifica esplicita dell'errore
- **Scenario principale:**
 1. Il sistema rileva la non validità della query
 2. Il sistema interrompe la ricerca
 3. Companion riceve un messaggio d'errore esplicativo

3 Analisi dei requisiti

UC08: Errore ricerca linked

- **Attore principale:** Companion
- **Precondizioni:**
 - Nel sistema è in corso una ricerca su una singola entità
 - Nel sistema si è verificato un errore durante la ricerca
- **Postcondizioni:**
 - Companion riceve notifica esplicita dell'errore
- **Scenario principale:**
 1. Il sistema interrompe la ricerca
 2. Companion riceve un messaggio d'errore esplicativo

UC09: Avvia test




Figura 20: Diagramma del caso d'uso: Avvia test

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Il sistema ha avviato l'esecuzione delle ricerche di test
- **Scenario principale:**
 1. Il supervisore seleziona l'avvio dei test
 2. Il sistema avvia i test
- **Trigger:** Il supervisore vuole avviare un test di performance

3 Analisi dei requisiti

UC10: Visualizza dashboard performance




Figura 21: Diagramma del caso d'uso: Visualizza dashboard performance

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Il supervisore ha visualizzato lo stato dell'ultima run di test avviata
- **Scenario principale:**
 1. Il supervisore visualizza l'id della run di test → UC10.1
 2. Il supervisore visualizza la lista delle metriche → UC10.2
- **Scenari alternativi:**
 - Nel sistema non vi sono run di test registrate → UC13
- **Inclusioni:**
 - UC10.1
 - UC10.2
- **Estensioni:**
 - UC13
- **Specializzazioni:**
 - UC11
 - UC12

UC10.1: Visualizza id run test

- **Attore principale:** Supervisore

3 Analisi dei requisiti

- **Precondizioni:**
 - Il supervisore sta visualizzando la dashboard delle metriche
 - Nel sistema sono presenti i dati relativi all'ultimo test svolto o in corso
- **Postcondizioni:**
 - Il supervisore ha visualizzato l'id relativo alla run di test a cui si riferiscono le performance
- **Scenario principale:**
 - Il supervisore visualizza l'id relativo alla run di test a cui si riferiscono le performance

3 Analisi dei requisiti

UC10.2: Visualizza metriche di performance

Sistema core - API

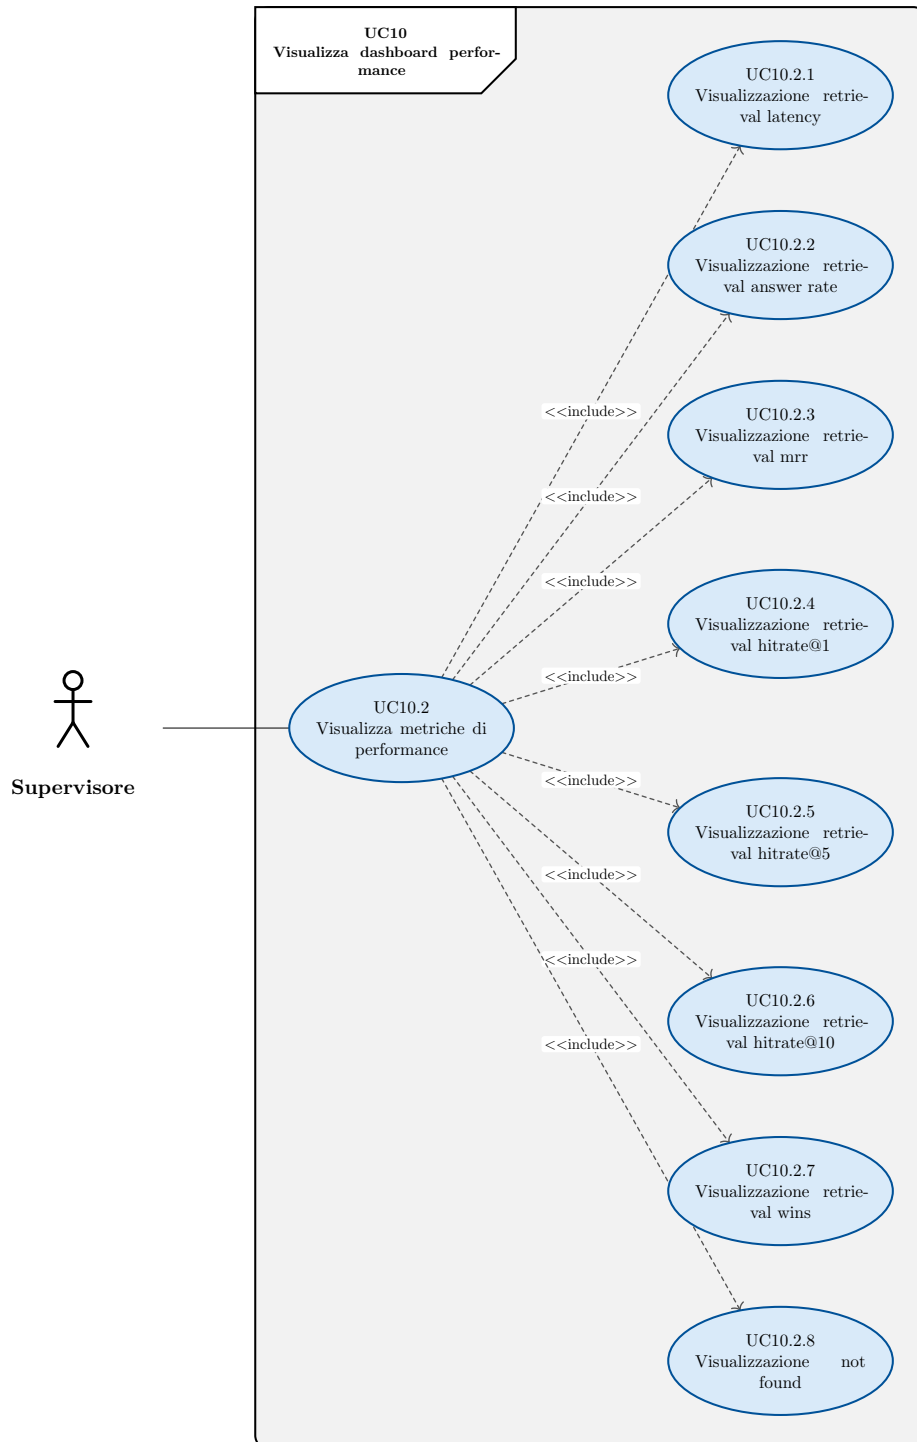


Figura 22: Diagramma del caso d'uso: Visualizza metriche di performance

3 Analisi dei requisiti

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Companion sta visualizzando la dashboard delle metriche
- **Postcondizioni:**
 - Il supervisore ha visualizzato la lista delle metriche
- **Scenario principale:**
 - Il sistema calcola le metriche
 - Il supervisore visualizza l'elenco delle metriche
 - Il supervisore visualizza la retrieval latency → UC10.2.1
 - Il supervisore visualizza la retrieval answer rate → UC10.2.2
 - Il supervisore visualizza la retrieval mrr → UC10.2.3
 - Il supervisore visualizza il retrieval hitrate@1 → UC10.2.4
 - Il supervisore visualizza il retrieval hitrate@5 → UC10.2.5
 - Il supervisore visualizza il retrieval hitrate@10 → UC10.2.6
 - Il supervisore visualizza il retrieval wins → UC10.2.7
 - Il supervisore visualizza il not found → UC10.2.8
- **Trigger:** Il supervisore vuole visualizzare le metriche di performance del sistema di retrieval

UC10.2.1: Visualizzazione retrieval latency




Figura 23: Diagramma del caso d'uso: Visualizzazione retrieval latency

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il supervisore sta visualizzando la lista delle metriche
 - Nel sistema sono presenti i dati relativi all'ultimo test svolto o in corso

3 Analisi dei requisiti

- **Postcondizioni:**
 - Il supervisore ha visualizzato la retrieval latency media
- **Scenario principale:**
 1. Il supervisore visualizza la retrieval latency media calcolata durante la presenza di un processo di ingestion → UC10.2.1.1
 2. Il supervisore visualizza la retrieval latency calcolata media durante l'assenza di un processo di ingestion → UC10.2.1.2
- **Inclusioni:**
 - UC10.2.1.1
 - UC10.2.1.2

UC10.2.1.1: Visualizzazione retrieval latency con ingestion attiva

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il supervisore sta visualizzando la lista delle metriche
 - Nel sistema sono presenti i dati relativi all'ultimo test svolto o in corso
- **Postcondizioni:**
 - Il supervisore ha visualizzato la retrieval latency media durante la presenza di un processo di ingestion
- **Scenario principale:**
 1. Il supervisore visualizza la retrieval latency media calcolata durante la presenza di un processo di ingestion

UC10.2.1.2: Visualizzazione retrieval latency con ingestion non attiva

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il supervisore sta visualizzando la lista delle metriche
 - Nel sistema sono presenti i dati relativi all'ultimo test svolto o in corso
- **Postcondizioni:**
 - Il supervisore ha visualizzato la retrieval latency media durante la assenza di un processo di ingestion
- **Scenario principale:**
 1. Il supervisore visualizza la retrieval latency media calcolata durante la assenza di un processo di ingestion

UC10.2.2: Visualizzazione retrieval answer rate

- **Attore principale:** Supervisore

3 Analisi dei requisiti

- **Precondizioni:**
 - Il supervisore sta visualizzando la lista delle metriche
 - Nel sistema sono presenti i dati relativi all'ultimo test svolto o in corso
- **Postcondizioni:**
 - Il supervisore ha visualizzato il retrieval answer rate
- **Scenario principale:**
 1. Il supervisore visualizza il retrieval answer rate

UC10.2.3: Visualizzazione retrieval mrr

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il supervisore sta visualizzando la lista delle metriche
 - Nel sistema sono presenti i dati relativi all'ultimo test svolto o in corso
- **Postcondizioni:**
 - Il supervisore ha visualizzato il retrieval mean reciprocal rank
- **Scenario principale:**
 1. Il supervisore visualizza il retrieval mean reciprocal rank

UC10.2.4: Visualizzazione retrieval hitrate@1

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il supervisore sta visualizzando la lista delle metriche
 - Nel sistema sono presenti i dati relativi all'ultimo test svolto o in corso
- **Postcondizioni:**
 - Il supervisore ha visualizzato il retrieval hitrate@1
- **Scenario principale:**
 - Il supervisore visualizza il retrieval hitrate@1

UC10.2.5: Visualizzazione retrieval hitrate@5

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il supervisore sta visualizzando la lista delle metriche
 - Nel sistema sono presenti i dati relativi all'ultimo test svolto o in corso
- **Postcondizioni:**
 - Il supervisore ha visualizzato il retrieval hitrate@5
- **Scenario principale:**
 - Il supervisore visualizza il retrieval hitrate@5

UC10.2.6: Visualizzazione retrieval hitrate@10

- **Attore principale:** Supervisore

3 Analisi dei requisiti

- **Precondizioni:**
 - Il supervisore sta visualizzando la lista delle metriche
 - Nel sistema sono presenti i dati relativi all'ultimo test svolto o in corso
- **Postcondizioni:**
 - Il supervisore ha visualizzato il retrieval hitrate@10
- **Scenario principale:**
 - Il supervisore visualizza il retrieval hitrate@10

UC10.2.7: Visualizzazione retrieval wins

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il supervisore sta visualizzando la lista delle metriche
 - Nel sistema sono presenti i dati relativi all'ultimo test svolto o in corso
- **Postcondizioni:**
 - Il supervisore ha visualizzato la retrieval wins
- **Scenario principale:**
 - Il supervisore ha visualizzato la retrieval wins

UC10.2.8: Visualizzazione not found

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il supervisore sta visualizzando la lista delle metriche
 - Nel sistema sono presenti i dati relativi all'ultimo test svolto o in corso
- **Postcondizioni:**
 - Il supervisore ha visualizzato il retrieval not found
- **Scenario principale:**
 - Il supervisore visualizza il retrieval retrieval not found

UC10.3: Visualizza metriche di consumo delle risorse

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il supervisore sta visualizzando la dashboard delle performance
- **Postcondizioni:**
 - Il supervisore ha visualizzato le metriche relative al consumo di risorse del DB.
- **Scenario principale:**
 1. ANCORA DA DECIDERE IN ATTESA DI INDICAZIONI DAL TUTOR

UC11: Visualizza dashboard performance test in corso

- **Attore principale:** Supervisore

3 Analisi dei requisiti

- **Precondizioni:**
 - Il sistema è attivo
 - Nel sistema è in corso una run di test
- **Postcondizioni:**
 - Il supervisore ha visualizzato lo stato in tempo reale dell'ultima run di test avviata
- **Scenario principale:**
 1. Il sistema mantiene aggiornata la dashboard
 2. Il supervisore visualizza l'id della run di test → UC10.1
 3. Il supervisore visualizza la lista delle metriche → UC10.2
- **Scenari alternativi:**
 - Nel sistema non vi sono run di test registrate → UC13

UC12: Visualizza dashboard performance test terminato

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il sistema è attivo
 - Nel sistema non sono in corso run di test
- **Postcondizioni:**
 - Il supervisore ha visualizzato lo stato dell'ultima run di test avviata
- **Scenario principale:**
 1. Il sistema calcola una singola volta i dati da mostrare
 2. Il supervisore visualizza l'id della run di test → UC10.1
 3. Il supervisore visualizza la lista delle metriche → UC10.2
- **Scenari alternativi:**
 - Nel sistema non vi sono run di test registrate → UC13

UC13: Nessuna run di test trovata

- **Attore principale:** Supervisore
- **Precondizioni:**
 - Il sistema è attivo
- **Postcondizioni:**
 - Il supervisore è stato informato dell'assenza di run di test
- **Scenario principale:**
 1. Il sistema non trova nessuna run di test da mostrare
 2. Il supervisore viene informato dell'assenza di run di test su cui calcolare le metriche

3 Analisi dei requisiti

3.2.3

3.3 Tracciamento dei requisiti

Ad ogni requisito è associato un codice costruito in base alle sue caratteristiche:

$$(F/Q/C)(M/D/O)R$$

F (*Functional*): definisce una funzione di un sistema o dei suoi componenti;

Q (*Qualitative*): rappresentano come il sistema deve essere per soddisfare i requisiti dello stakeholder;

C (*Constraint*): rappresentano dei vincoli o dei limiti che il sistema deve rispettare;

M (*Mandatory*): irrinunciabili per qualcuno degli stakeholder;

D (*Desirable*): non strettamente necessari ma a valore aggiunto riconoscibile;

O (*Optional*): relativamente utili oppure contrattabili anche in fasi avanzate del progetto;

R (*Requirement*): requisito

In Tabella 1, Tabella 2 e Tabella 3 sono riassunti i requisiti e il loro tracciamento con gli use case delineati in fase di analisi.

Codice	Descrizione	Fonti
--------	-------------	-------

Tabella 1: Tracciamento dei requisiti funzionali.

Codice	Descrizione	Fonti
--------	-------------	-------

Tabella 2: Tracciamento dei requisiti di qualità.

Codice	Descrizione	Fonti
--------	-------------	-------

Tabella 3: Tracciamento dei requisiti di vincolo.

3 Analisi dei requisiti

Di seguito, nella Tabella 4 ho inserito il riepilogo dei requisiti, suddivisi per tipologia e necessità.

Tipo	Manda- tory	Desirable	Optional	Somma
Functional	Totale			

Tabella 4: Riepilogo dei requisiti.

3 Analisi dei requisiti

Capitolo 4

Introduzione Teorica

In questo capitolo approfondisco le basi teoriche rilevanti per la realizzazione del progetto, le tecnologie rilevanti per il progetto e relativi ruoli nella risoluzione dei problemi affrontati, quali strumenti sono stati adottati e altri strumenti adottati durante lo sviluppo.

4.1 Aspetti Teorici

4.2 Tecnologie

4.3 Strumenti

4 Introduzione Teorica

Capitolo 5

Descrizione del Lavoro Svolto

In questo capitolo approfondisco le problematiche affrontate nel concreto e le relative soluzioni.

5.1 TODO

Definire la struttura del capitolo.

5 Descrizione del Lavoro Svolto

Capitolo 6

Conclusioni

In questo capitolo traggio le conclusioni sul progetto.

6.1 Consuntivo finale

Una volta terminato il progetto ho redatto il consuntivo orario finale nella Tabella 5 che suddivide in maniera approssimata le ore dedicate alle varie fasi.

Fase	Ore
<i>Onboarding</i> del progetto	5
Analisi dei requisiti	30
...	...
Totale	320

Tabella 5: Consuntivo orario finale.

6.2 Raggiungimento degli obiettivi

6.3 Requisiti soddisfatti

Arrivato alla fine del progetto ho implementato...

)

6 Conclusioni

6.4 Rischi occorsi e mitigati

I rischi emersi durante lo stage sono riportati in Tabella 6.

Descrizione	Mitigazione
R1 – Descrizione del rischio	Soluzione

Tabella 6: Rischi occorsi con la loro mitigazione.

6.5 Valutazione personale

Glossario

Elasticsearch: Motore di analisi e ricerca distribuita. Funge da piattaforma di retrieval e salva dati strutturati, non strutturati e dati vettoriali. 5

LLM – Large Language Model: Modello di intelligenza artificiale addestrato su enormi quantità di testo per comprendere e generare linguaggio naturale, come GPT, Gemini o Mistral. Viene impiegato in compiti di analisi, estrazione di informazioni e generazione testuale. 5

Pgvector: Estensione per PostgreSQL, un database management system, che semplifica l'utilizzo dei vettori, consentendoti di archivarli, cercarli e indicizzarli direttamente nel tuo database relazionale. 5

RAG – Retrieval Augmented generation: Tecnica che permette ai LLM di reperire e incorporare informazioni da fonti di dati esterne.

Questo permette di recuperare informazioni rilevanti da database, documenti caricati, fonti web, ecc...

Il vantaggio principale è l'attualità delle risposte fornite dall'LLM e la possibilità di non dover usare documenti privati in fase di addestramento. 5

Bibliografia